BOND-TERMS

Rapport de cadrage

Extraction des conditions des obligations à partir des documents de l'ESMA

Nathan Mang
23 octobre 2026
Version 0.0, avant toute extraction

Table des matières

Synthèse 2

1 Le besoin 2

2 Les données 3

3 La population étudiée 4

4 Vérité terrain et critères de succès 5

5 La référence humaine 6

6 Business case 7

7 Risques et limites 7

8 Suite du projet 7

Synthèse

Quand une banque, une société de gestion ou un assureur achète une obligation, son équipe « référentiel titres » crée une fiche décrivant le titre : devise, montant, échéance, taux, rang de la dette. Ces informations figurent dans les documents juridiques de l'émission, des PDF déposés auprès des régulateurs et publiés par l'ESMA, l'Autorité européenne des marchés financiers. Aujourd'hui, la fiche est saisie à la main ou achetée à un fournisseur de données.

Le projet bond-terms propose d'extraire ces conditions automatiquement, chaque valeur étant accompagnée d'une citation exacte du document, vérifiée par le code. Les cas douteux sont envoyés en revue humaine, et un rapport signale les écarts entre le document et la base de référence européenne FIRDS.

Ce rapport fixe le cadre avant toute extraction : la population étudiée, la vérité terrain, les seuils de réussite et la référence humaine. Il s'appuie sur des mesures reproductibles, faites avec les scripts de `scripts/feasibility`.

— La population retenue compte 838 obligations classiques à ISIN français, émises par huit groupes de la banque, de l'assurance, du luxe et de l'aviation. Environ 500 documents sont attendus.

— L'indicateur principal ne repose que sur des valeurs officielles (FIRDS et GLEIF), sans annotation manuelle.

— Une saisie manuelle chronométrée de dix documents prend 3 minutes par document en médiane, avec 82 % de champs justes. L'outil devra atteindre 95 à 98 % selon les champs.

— Deux défauts de la définition de la population ont été trouvés et corrigés pendant le cadrage, avant toute extraction.

1. Le besoin

1.1 L'utilisateur et son problème

L'utilisateur visé est l'équipe référentiel titres d'une banque ou d'une société de gestion. Pour chaque nouvelle obligation, elle doit renseigner une fiche exacte : une échéance fausse ou une option de remboursement oubliée fausse ensuite les valorisations, les calculs de risque et les déclarations réglementaires. Les sources sont les conditions définitives (*final terms*), un document de 8 à 18 pages qui fixe les conditions d'une émission précise, en complément d'un long prospectus de base.

1.2 Pourquoi ce n'est pas déjà résolu

La base FIRDS de l'ESMA publie déjà les champs de base de chaque titre. Elle ne contient pas les clauses qui comptent pour un analyste (remboursement anticipé, label vert, garant) et peut s'écarter du document juridique. Les fournisseurs de données (Refinitiv, Bloomberg) sont payants. Je n'ai trouvé aucun outil libre qui extrait ces conditions et les vérifie sur FIRDS.

2. Les données

2.1 Trois sources publiques

Source	Contenu et accès
FIRDS (ESMA)	Base de référence des instruments financiers : fichiers complets chaque semaine, mises à jour chaque jour, sans clé. Publication utilisée : 17 octobre 2026.
Registre des prospectus (ESMA)	Documents approuvés par les autorités nationales, avec leurs ISIN ; PDF téléchargeables, sans clé.
GLEIF	Identifiants LEI des émetteurs, sous licence CC0, par une API sans clé.

L'ESMA autorise la reproduction de ses contenus si la source est citée. Le dépôt ne contient aucun document de l'ESMA : seulement des identifiants, des liens et des chiffres calculés. Les requêtes vers l'ESMA sont espacées et mises en cache.

2.2 Ce que contient FIRDS

Les quatre fichiers de la catégorie dette publiés le 17 octobre 2026 pèsent environ 450 Mo chacun une fois décompressés. Ils sont lus en flux : 1 744 381 enregistrements, 631 239 titres distincts, en 17 minutes et avec un pic de mémoire de 103 Mo, compatible avec un poste de 8 Go. L'échéance et le montant sont toujours renseignés, le rang de la dette dans 25 % des cas. Après exclusion des produits structurés (section 3), il reste 112 339 obligations classiques, dont 5 243 à ISIN français.

2.3 Ce que contient le registre

Le registre compte 6,5 millions de documents déposés entre janvier et septembre 2026, presque tous des produits structurés allemands (certificats, warrants). Un tirage au hasard ne trouve aucune obligation classique. Mesuré par segment, sur 60 documents tirés au hasard :

Segment	Documents	Dans FIRDS (dette)	Obligations classiques
Tous pays	6 503 900	2 sur 60	0 sur 60
France, conditions définitives	8 201	38 sur 60	6 sur 60
Irlande	18 317	55 sur 60	4 sur 60
Luxembourg	56 637	4 sur 60	1 sur 60
Pays-Bas	14 263	0 sur 60	0 sur 60
Hors conditions définitives	3 534	5 sur 60	3 sur 60

Table 1 – Part d'obligations classiques par segment du registre (`correspondance-registre-firds.csv`).

La collecte part donc de FIRDS : on prend les obligations en circulation, puis on cherche leurs documents par ISIN.

3. La population étudiée

3.1 Huit émetteurs

Émetteur	Secteur	Obligations à ISIN FR	ISIN avec document
BNP Paribas	banque	251	4 sur 8
Société Générale	banque	142	4 sur 8
Crédit Agricole S.A.	banque	202	6 sur 8
BPCE	banque	200	4 sur 8
AXA	assurance	4	2 sur 4
LVMH	luxe	13	6 sur 8
Kering	luxe	16	6 sur 8
Air France-KLM	aviation	10	4 sur 8
Total		838	36 sur 60

Table 2 – Couverture des émetteurs (`couverture-emetteurs.csv`). Hermès n'a aucune obligation dans FIRDS. Les LEI sont vérifiés auprès de GLEIF.

Les ISIN français sont retenus parce que les ISIN « XS » ont rarement un document dans le registre et que les ISIN « US » ou « CH » relèvent d'autres régulateurs. Avec 60 % d'ISIN trouvés, on peut attendre environ 500 documents.

3.2 Une définition corrigée deux fois

Une obligation classique est, dans `bond_terms.instruments.is_plain_bond`, un titre de code CFI DB ou DT, avec un taux fixe compris entre 0 et 10 % ou un taux variable indexé sur une vraie référence. Cette définition a été corrigée deux fois pendant le cadrage, avant toute extraction :

— **Lecture des références de FIRDS.** FIRDS écrit la référence d'un taux variable sous trois formes ; la forme par code (`<Indx>EURI</Indx>`) n'était pas lue. Ces titres avaient une référence vide et étaient exclus à tort. L'erreur a été signalée par une relecture externe du dépôt. La lecture est désormais testée sur les trois formes, garde la durée de la référence, et un contrôle vérifie qu'aucun taux variable n'est resté sans référence.

— **Produits structurés déguisés.** La saisie chronométrée a fait apparaître un titre au coupon de « 60 % payable in arrear », décrit dans FIRDS comme un taux variable de référence OTHER. Dans la population, 85 titres avaient cette référence et 240 un « taux fixe » au-dessus de 10 % : des coupons cumulés de produits structurés pour particuliers, presque tous de Société Générale. Ils sont désormais exclus ; le seuil de 10 % vient de la distribution mesurée. La population est passée de 1 163 à 838 obligations.

La population a été définie à partir des données, puis vérifiée sur de vrais documents. Les deux corrections sont tracées dans l'ADR 0001, avec leurs chiffres avant et après.

4. Vérité terrain et critères de succès

4.1 Une vérité officielle, sans annotation

Je ne suis pas spécialiste de la finance de marché. Une vérité terrain annotée par un seul non-spécialiste fausserait la mesure. L'indicateur principal porte donc uniquement sur des champs publiés par une source officielle (niveau A) :

Champ	Règle de comparaison
Devise, date d'échéance, type de taux	Égalité exacte avec FIRDS
Taux fixe	Égalité à 4 décimales
Taux variable	Même référence, même durée, marge égale en points de base
Valeur nominale par titre	Égalité exacte
Montant nominal total	Seulement pour un ISIN à document unique (une émission abondée change le total)
Rang de la dette	Seulement quand FIRDS le renseigne
LEI de l'émetteur	Égalité exacte avec FIRDS, nom contrôlé par GLEIF

Le niveau B porte sur quelques rubriques littérales (remboursement au gré de l'émetteur ou du porteur, remboursement *make-whole*, affectation verte). Environ 50 documents seront annotés deux fois à une semaine d'écart ; ce niveau reste indicatif, sans seuil. Le LLM juge est abandonné, faute de vérité fiable pour le calibrer.

4.2 Découpage et seuils

Les documents sont triés par date d'approbation ; les 30 % les plus récents forment le test, ouvert une seule fois. La date de coupure sera calculée sur les seules métadonnées et versionnée avant toute extraction.

Indicateur, sur le test	Seuil
Échéance, devise, type de taux, taux fixe	au moins 98 % chacun
Marge, valeur nominale, montant, rang	au moins 95 % chacun
Valeur sans citation retrouvée dans le document	refusée, comptée fausse
Documents envoyés en revue humaine	au plus 30 %
Rapport d'exceptions	au moins 80 % de vrais écarts
Coût	0 €

Chaque seuil se juge sur l'estimation, avec l'intervalle à 95 % publié à côté : avec environ 150 documents de test, une exactitude de 98 % est connue à environ 2,2 points près. La référence à battre est un extracteur à règles fondé sur les rubriques numérotées des conditions définitives. Le LLM n'est retenu que s'il fait au moins 2 points de mieux en exactitude globale (sur les paires document–champ), avec une borne basse de l'intervalle (bootstrap par document) au-dessus de zéro.

5. La référence humaine

5.1 La saisie chronométrée

J'ai saisi à la main les champs du niveau A de dix documents approuvés en 2022 ou 2023, avec Ctrl+F et copier-coller, sans autre source, puis j'ai comparé ma saisie à FIRDS avec les règles ci-dessus.

— **Temps** : 28 minutes pour dix documents, 3 minutes par document en médiane, à une minute près.

— **Exactitude** : 58 champs justes sur 71, soit 82 %, sur les neuf obligations classiques. Le document 6 s'est révélé être un produit structuré et ne compte que pour le temps.

Champ	Justes	Comparés
Devise, échéance, type de taux	27	27
Valeur nominale	8	9
Taux fixe	7	8
Référence et marge du taux variable	2	2
Rang	5	7
LEI de l'émetteur	5	9
Montant nominal total	4	9

Table 3 – Saisie humaine comparée à FIRDS (`chronometrage-resultats.json`).

5.2 Ce que les erreurs apprennent

— **Le piège de la recherche.** Chercher « Aggregate Nominal Amount » mène aussi à la ligne « Issue Price: 99.513 per cent. of the Aggregate Nominal Amount » : quatre fois, le prix d'émission a été saisi à la place du montant. L'extracteur devra s'ancrer sur l'intitulé numéroté de la rubrique.

— **La ligne recopiée.** Un document a reçu les valeurs du précédent, sauf l'échéance : une erreur humaine typique de fin de série.

— **Les identifiants.** Deux LEI manquent et un a perdu son premier caractère. Un LEI et un ISIN portent une clé de contrôle : l'outil la vérifiera.

— **Un premier écart réel.** Pour le document 10, le PDF annonce 30 millions d'euros et FIRDS 7,5 millions. Même une lecture juste aurait été comptée fausse : c'est ce que le rapport d'exceptions devra signaler.

La fiche de saisie n'avait pas de colonne pour la durée de la référence d'un taux variable : ce champ n'a pas été comparé. Les documents chronométrés devraient se trouver dans la partie développement ; ce sera vérifié une fois la coupure calculée, et un document tombé dans le test en sera retiré.

6. Business case

Le gain se calcule par une formule dont les termes seront mesurés, pas supposés :

$$\text{gain} = N \times (t_{\text{manuel}} - t_{\text{revue}}) + N \times (e_{\text{manuel}} - e_{\text{outil}}) \times c_{\text{erreur}}$$

où N est le nombre de documents traités, t le temps par document et e le nombre d'erreurs par document. Les termes manuels sont mesurés : $t_{\text{manuel}} = 3$ minutes et $e_{\text{manuel}} = 13/9 \approx 1{,}4$ champ faux par document. Les termes de l'outil seront mesurés sur le test. Le coût d'une erreur, c_{erreur}, dépend de l'usage de la fiche ; il restera un paramètre explicite plutôt qu'un chiffre inventé.

Pour l'ordre de grandeur, les 500 documents attendus représentent environ 25 heures de saisie manuelle et, au taux mesuré, environ 700 champs faux à rattraper.

7. Risques et limites

— **Volume** : environ 150 documents de test laissent une incertitude de l'ordre de 2 points ; elle sera publiée avec chaque résultat.

— **Référence humaine** : une seule personne, non spécialiste, sur dix documents. C'est un ordre de grandeur, pas une mesure de la profession.

— **FIRDS n'est pas parfait** : le document 10 montre un écart sur le montant. Les écarts seront examinés un par un dans le rapport d'exceptions.

— **Évolution des sources** : le registre change en continu, et le Listing Act modifie le régime des prospectus. La collecte gardera les dates et les versions des données utilisées.

8. Suite du projet

Version	Contenu
v0.1	Collecte (FIRDS, registre, PDF), date de coupure versionnée, entrepôt de données
v0.2	Extracteur à règles contre LLM sur le niveau A, test ouvert une fois
v0.3	Niveau B, file de revue humaine, rapport d'exceptions
v0.4	API, collecte planifiée, surveillance de la qualité des données
v1.0	Démonstration publique, note de synthèse et business case mesuré

Les décisions de ce cadrage sont consignées dans l'ADR 0001 (`docs/adr/0001-cadrage.md`).